

手语翻译系统：同一问题，隔六年，两代技术

薛受浩 · 墨尔本大学软件工程硕士 · 2026-09 · 独立完成 · 代码 github.com/XUE-melb/sign-language-translation (公开)

1.13 → 18.93

test BLEU-4，四阶段消融
(3 seed 均值)

+13.03

换 LLM 解码器这一步的贡献，配对 bootstrap
 $p<0.001$

43–83%


陌生手语者上的保留率（留一手语者，三人）

30 条

决策日志，每条含数据依据、预判与对账

做了什么

把六年前本科做过的"手语视频 → 中文句子"重做一遍：用 **CE-CSL** (5,988 条真实场景视频，12 位手语者) 作数据，走 gloss-free 路线，从老架构基线出发**每次只换一个组件**，量化每一代技术各自值多少；并把模型接成可用的系统。



四阶段消融表（核心产出）

阶段	改动（单变量）	BLEU-4	ROUGE-L	相邻行显著性
0	老架构：关键点 → BiLSTM + 注意力 LSTM 解码器	1.13 ± 0.15	20.38	—
1	只换视觉编码器：冻结的 Uni-Sign 预训练时空 GCN	3.76 ± 0.29	29.61	3/3 seed $p<0.001$
2	只换解码器：LSTM → mT5-base（冻结）+ LoRA $r=16$ + 可训投影层	16.79 ± 0.23	47.50	3/3 seed $p<0.001$
3	解冻视觉编码器，端到端微调	18.93 ± 0.58	50.15	2/3 seed 显著

阶段 1、2 借用了 Uni-Sign 在 CSL-Daily 上微调过的编码器与 mT5。借来的系统不训练直接跑 CE-CSL 是 dev 3.09，适配训练后 16.2，差值是本项目自己的贡献。测试集 500 条只评一次，dev 选点；指标为 sacrebleu 字级 BLEU-4。

补充实验与 Agent 层

- **陌生手语者**：留一手语者实验，同片段保留 43% (E) / 78% (A) / 83% (D)；解冻编码器把 E 从 43% 提到 73%，关键点增广无效。
 - **LoRA 值多少**：去掉 LoRA 只训投影层 13.41，LoRA 贡献 +3.4。
 - **训练预算**：30 轮 vs 60 轮差 0.38，按预登记规则选 60 轮，两行都保留。
- **置信度校准**：beam 分数分 5 桶，BLEU-4 从 8.5 单调升到 32.5 (Spearman 0.43) → 门控阈值 $\tau=0.7$ 。
 - **LLM 重排**：Claude 只在 4 候选里选，test 集 19.79 → 21.86 (上限 27.01)。
 - **门控**：裁判追问 56%，直接输出部分 30.5 vs 追问部分 15.1；500 句评测成本 \$2.86。

可运行的系统

手语翻译 Demo

E003_enc1e-4_s3456 · cuda

● 服务在线

🔄

输入

空闲

▶ 测试集回放

📶 上传视频

📹 摄像头录制

播放的是数据集的关键点骨架，不是视频。每一帧经 WebSocket 送到服务端，译文随帧数增长而更新——这就是请侧只传坐标不传画面的 C 层架构。

手语者

E (54 条)

片段

00207 · 我喜欢在家里看电视。

部分结果间隔


每 30 帧

▶ 播放并翻译

随机一条

☒ 翻译完成后隐藏参考句

124 / 124 帧



|| 暂停

30 fps

译文

4.3 s

我喜欢在家里看电影。

最终 · 124 帧 · beam 4 · 164 ms

1 我喜欢在家里看电影。

88%

2 我喜欢在家里看电视。

76%

3 我很喜欢在家里看电影。

73%

4 我喜欢在家看电视。

73%

参考句：我喜欢在家看电视。

Agent 面板

裁判：anthropic (LLM 只在候选里选)

✓ 裁判 (anthropic, 2271 ms)：选第 1 条「我喜欢在家里看电影。」，直接输出。理由：各候选仅措辞差异，首选通顺且置信最高。

确认阈值 τ (平均 token 概率低于 τ 就追问)：0.70



test 集校准： $\tau=0.7$ 时 65% 的句子直接输出 (BLEU-4 24.3)，其余追问 (11.3)；见 D-028

✓ 置信度 $88\% \geq \tau$ ，直接输出：我喜欢在家里看电影。

记入对话：我喜欢在家里看电影。

浏览器 demo：左侧播放测试片段的关键点骨架并逐帧推流；右侧译文随帧数更新，最终给出 4 条候选与置信度；下方 Agent 面板显示裁判选择与理由。三种输入：测试集骨架回放、上传视频、摄像头录制。FastAPI + WebSocket，本地 RTX 5060 每句 0.2 秒，已部署到云端 GPU 服务器供远程访问。

工程与方法

- 关键点提取管线：多进程、断点续跑、逐片段质检并按手语者归因；定位并修复 onnxruntime 报告 CUDA 可用却静默回退 CPU 的问题，2.2 s/帧 → 25 ms/帧。
- 训练脚本支持冻结/解冻编码器、LoRA / 全量微调、留一手语者、关键点增广、中英两种语言，一套代码跑完所有实验。
- 评测：BLEU-1..4、chrF、ROUGE，自动计算"打乱配对"地板，配对 bootstrap 显著性。
- 30 条决策日志：每条写明当时的问题、否掉的方案、支撑数据、代价与风险；实验的预判写在结果之前，两条预判被推翻并如实记录。
- ASL 迁移实验 (How2Sign, 35k 句)：三趟实验给出负结果 (最好 2.55，地板 1.3)，逐个排除"数据""容量"假设，定位为缺少目标语言的预训练视觉表征。
- 技术栈：PyTorch、transformers / peft、sacrebleu、FastAPI、rtmlib / onnxruntime、Anthropic SDK、Playwright 测试。

诚实的边界

- 数字是 signer-dependent 官方划分下的，与文献榜单不可直接比较；gloss-free、单数据集。
- 视觉编码器与 mT5 借自 Uni-Sign (CC-BY-NC 4.0)，本项目训练的是投影层、LoRA 与端到端微调，共 4.3M–8.9M 参数；权重不在公开仓库中。
- 陌生手语者上翻译质量大约减半；demo 页面对此明示。

完整记录：仓库内 docs/DECISIONS.md (决策)、docs/EXPERIMENTS.md (实验表)、docs/STATE.md (状态)。

CE-CSL Uni-Sign mT5 LoRA FastAPI WebSocket Claude API